

Типы локальных экономик России: кластеризация динамической атрибутированной сети муниципалитетов

Методологический отчёт. Трек «Кластеризация», онлайн-конкурс СберИндекса 2026. Автор — Андрей Лебедев.
Интерактивный лендинг: <https://lebedev-git.github.io/sberindex-mo-clusters/> · код и данные: <https://github.com/lebedev-git/sberindex-mo-clusters>

Главное

- **2 016 муниципалитетов → 4 макротипа → 6 типов локальных экономик.** Макротипы: «Столичные агломерации» (330 МО), «Города» (610), «Сельская Россия» (991), «Север» (85). Типы в основном вложены в макротипы (вложенность 92,7%): сельская Россия делится на «Глубинку европейской части и Урала» и «Аграрную периферию с летним пиком», ядро севера — «Арктика и Крайний Север». «Удалённая Сибирь и горы» — переходный тип: его МО на макроуровне делятся между «Городами» (57%), «Севером» (25%) и «Сельской Россией» (19%).
- **Метод выбран правилом, а не на глаз.** KEFRiN (Shalileh & Mirkin, 2022) на сети синхронности трат с долей сети 0,4. Правило Коупленда по 45 конфигурациям (5 методов × k = 4...12; голосуют 6 индексов качества и устойчивости) ставит KEFRiN k = 4 на первое место (устойчивость ARI 0,975) — это метод и макроуровень. Детальный уровень — тот же метод (иначе уровни не вложены) при наименьшем k ≥ 6 с ARI ≥ 0,75: KEFRiN k = 6 (ARI 0,78); результат не меняется при пороге устойчивости от 0,65 до 0,75. Совпадение правила и конфигурации проверяет код (`results/selection.json`).
- **Типы согласуются с официальными категориями территорий, которых модель не видела:** сильно — с Севером и Арктикой, умеренно — с моногородами, агломерациями и столицами (V Крамера 0,22–0,27). Все МО типа «Арктика и Крайний Север» — районы Крайнего Севера, две трети — Арктическая зона; V Крамера с Арктической зоной 0,59, с Крайним Севером 0,52. Типы объясняют 43% разброса логарифма численности населения (Росстат) и 40% разброса индекса доступности рынков.
- **Динамика.** Из 656 формальных смен типа между 2023 и 2024 годами значимы 116 (уверенная принадлежность в обоих годах). Главный сдвиг однонаправленный: у 84 МО «Аграрной периферии» исчез летний подъём трат в общепите (переход в «Глубинку»; медиана летнего избытка общепита к стране +1% в 2023 → −5% в 2024, у оставшихся в типе +5% → +10%; по общим тратам 0% → −0,7%), обратно — 23 (биномиальный тест на симметрию $p \approx 2 \cdot 10^{-9}$).
- **Международная проверка.** В США открытые карточные данные по округам не восстанавливают официальные производственные типы экономик (ARI 0,03; в США доступен только общий индекс трат, без структуры корзины): типология по тратам дополняет производственную классификацию, а не заменяет её. Поэтому названия типов описывают уклад потребления и проверяются российскими официальными метками.

Коротко, без формул

Для каждого муниципалитета есть 24 месяца трат жителей — всего и по пяти категориям. Из них считаются девять признаков: уровень трат, структура корзины и сезонность, всё относительно медианы страны в тот же месяц, поэтому инфляция и общий рост безналичных платежей на тип не влияют. Затем строится сеть: каждый муниципалитет соединяется с 15 самыми похожими по тому, как колеблются его траты месяц к месяцу. Метод KEFRiN ищет группы, внутри которых муниципалитеты похожи и по признакам, и по связям в сети. Метод и число групп выбирает правило голосования шести индексов качества и устойчивости, а не автор; остальные пороги заданы правилами в конфигурации и проверены на чувствительность. Итог проверяется данными, которых модель не видела.

Термин	Что значит
МО	муниципальное образование: район, муниципальный или городской округ, район города
Силуэт (SW)	насколько МО ближе к своему типу, чем к соседнему; от −1 до 1
Модулярность (MQ)	доля связей сети внутри типов сверх случайной
AVI / AVU	обособленность типов в сети / «перемешанность» связей между типами

Термин	Что значит
ARI	совпадение двух разбиений: 1 — одинаковые, 0 — как случайные
η^2 , V Крамера	доля различий внешнего показателя, объясняемая типами; сила связи с категорией (0–1)
Правило Коупленда	вариант побеждает другой, если лучше по большинству индексов; счёт — победы минус поражения

1. Задача и логика решения

Нужно найти скрытую структуру экономического пространства страны: сгруппировать экономически схожие муниципалитеты (МО), проследить, как группы меняются во времени, и объяснить их как реальные типы локальных экономик. Мы смотрим на экономику МО «со стороны кошелька»: сколько и на что тратят жители.

Логика решения:

1. **Узел** — МО со своими атрибутами: уровень трат, структура корзины, сезонность.
2. **Ребро** — экономическая близость. Сравниваем пять правил; основное — синхронность колебаний трат, потому что она добавляет к атрибутам новую информацию, а не дублирует их (раздел 4).
3. **Кластеризация сети с признаками** — KEFRiN (Shalileh & Mirkin, 2022) против четырёх альтернатив на одних и тех же узлах, признаках и рёбрах; качество — полный набор ICVI из Положения.
4. **Динамика** — 13 скользящих годовых окон: каждое окно — своя сеть и своё разбиение, номера типов сохраняют смысл благодаря якорному старту. Переход считается значимым, только если МО уверенно принадлежит разным типам в непересекающихся 2023 и 2024 годах.
5. **Интерпретация** — профили в рублях и долях, правило Миркина, типичные представители (медоиды) и внешняя проверка признаками, которых модель не видела.

2. Данные

Набор	Содержание	Использование
consumption.parquet	Средние безналичные траты жителя МО за месяц, руб.; 6 категорий («Все категории», продовольствие, здоровье, общепит, транспорт, маркетплейсы); 2023-01...2024-12; 2 190 МО	Признаки узлов, ряды для рёбер
market_access.parquet	Индекс доступности рынков 2024 (гравитационная формула, 0–1000)	Только внешняя проверка и интерпретация
connection.parquet	Автодорожные и ж/д расстояния между центрами МО	Правило рёбер «дороги», география рёбер
Справочник МО	Названия, вид МО, регион, ОКТМО, центры, границы (версия 2024)	Подписи, внешняя проверка, карта

Панель. В анализ входят 2 016 МО с полными 24-месячными рядами во всех шести категориях. 174 МО из 52 регионов исключены из-за пропусков. В Бурятии (данные только за 2023 год), Дагестане, Ингушетии и Чечне полного ряда нет ни у одного МО: из 100 МО справочника в данных есть 41, все с пропусками. Ещё 151 МО справочника в остальных регионах (например, 22 в Московской области) в данных о расходах нет совсем. В наборе организатора полностью отсутствуют Краснодарский край, Ростовская, Белгородская, Брянская, Курская, Воронежская области, Республика Крым и Севастополь — поэтому, например, черноморских курортов в типологии нет. Донецкой и Луганской Народных Республик, Запорожской и Херсонской областей нет ни в справочнике МО, ни в данных о расходах: на карте лендинга они показаны контурами субъектов (geoBoundaries, ODbL) и в расчёты не входят. Поле расходов в файле называется value (в описании набора — consumption).

Траты номинальные и относятся только к безналичным операциям. Поэтому все признаки центрированы медианой страны в том же месяце: тип описывает **относительное** положение МО, а не инфляцию и общий рост безналичных платежей.

3. Признаки узлов

Для МО i , месяца t и категории j обозначим T_{it} — траты «Все категории», c_{ijt} — траты категории. Для окна из L месяцев:

- **Уровень:** $level_i = mean_t [ln T_{it} - median_i ln T_{it}]$.
- **Профиль (CLR):** $clr_{ijt} = ln c_{ijt} - mean_j ln c_{ijt}$; $profile_{ij} = mean_t [clr_{ijt} - median_i clr_{ijt}]$ — центрированный лог-профиль пяти категорий, отделённый от общего уровня.
- **Сезонность сверх общероссийской:** $e_{it} = (relT_{it} - mean_t relT_{it})$, где $relT_{it} = ln T_{it} - median_i ln T_{it}$; признаки — амплитуда $std_t e_{it}$, летний избыток $mean_{\{июн-авг\}} e_{it}$ и такой же летний избыток общепита.

Итого 9 признаков в трёх блоках. Масштабирование робастное (медиана и межквартильный размах по полному периоду, затем фиксировано для всех окон); блок делится на $\sqrt{\text{число признаков}}$ и умножается на вес блока из конфигурации (уровень 1, профиль 1, сезонность 0,7), чтобы блоки вносили сопоставимый вклад в расстояние: их доли общего разброса — 31%, 36% и 33% (раздел 5).

4. Сеть: пять правил рёбер

Все сети строятся на одних и тех же 2 016 узлах как симметризованный граф к ближайших соседей ($k = 15$): ребро есть, если j среди соседей i или наоборот. Основная сеть связна уже при $k = 3$; $k = 15$ (средняя степень ≈ 25 , около 1% узлов) — компромисс: при малом k рёбра зависят от шума отдельных корреляций по 24 точкам, при большом сеть размывается и теряет локальную структуру. Устойчивость типологии к k (5–30) — в `results/knn_sensitivity.csv` (раздел 5).

Правило	Близость	Вес ребра
attr — признаки	евклидово расстояние в пространстве признаков	$\exp(-d^2/(\sigma_i \sigma_j))$, σ — расстояние до k -го соседа
corr — синхронность	корреляция Пирсона идиосинкратических рядов: $\ln$ трат минус медиана страны и минус собственное среднее, каждый из 6 каналов нормирован, каналы склеены	корреляция
cosine — корзина	косинус векторов средних трат по 5 категориям	косинус
dtw — лаги	многомерное DTW по нормированным рядам с окном Сакое–Тибы 2 мес. (опережение/запаздывание)	как у attr
road — география	автодорожное расстояние между центрами МО	как у attr

Правило	Рёбер	Ср. степень	Компонент	Гомофилия	Внутри региона	Медиана длины ребра, км	ARI KEFRiN с итогом	NMI сообществ Leiden с регионом
attr	21 519	21,3	1	0,86	21%	817	0,89	0,33
corr (основное)	25 176	25,0	1	0,55	27%	652	1,00	0,31
cosine	19 666	19,5	1	0,66	16%	943	0,86	0,33
dtw	25 373	25,2	1	0,53	25%	753	0,90	0,32
road	18 673	18,5	12	0,50	72%	106	0,88	0,77

Пересечение рёбер между правилами (Жаккар) — от 0,04 до 0,11, кроме corr–dtw (0,56). Итоговая типология почти не зависит от правила рёбер: KEFRiN на любой из пяти сетей даёт ARI 0,86–0,90 с итогом — при доле сети 0,4 сеть уточняет границы типов, а не создаёт их.

Почему основное правило — синхронность (corr). Сеть должна добавлять к атрибутам то, чего в них нет. Рёбра corr почти не совпадают с рёбрами по признакам (индекс Жаккара $\approx 0,08$), но согласованы с ними (гомофилия $\approx 0,55$): синхронно колеблются экономически похожие МО, хотя «соседство» по синхронности — другая информация,

чем «соседство» по профилю. Сеть по признакам дублирует признаки (сравнение атрибутивных и сетевых метрик на ней не было бы независимым). Дорожная сеть почти целиком повторяет административную географию (сообщества Leiden совпадают с регионами, NMI $\approx 0,77$) — она полезна как объяснение, но не как экономическая близость. DTW даёт близкую к corr сеть (Жаккар $\approx 0,56$), то есть сдвиги во времени на 1–2 месяца структуру почти не меняют.

Что меняет сеть (results/justification.json). KEFRiN и k-means при $k = 6$ на тех же признаках совпадают на ARI 0,83: сеть переводит в другой тип 136 МО из 2 016. Это пограничные МО: их силуэт и у k-means около нуля (0,06; у KEFRiN –0,01). Сеть решает такие случаи в пользу синхронности: доля связей синхронности этих МО внутри своего типа растёт с 35% до 57% (по всем МО — с 61% до 64%). Ядро типов задают признаки, сеть уточняет границы — поэтому типология почти не зависит от правила рёбер.

5. Методы кластеризации

Все методы работают на одних узлах, признаках X и сети A :

- **k-means** и **Ward** — только признаки (базовые линии без сети);
- **спектральная кластеризация** — смесь нормированных kNN-сходств по признакам и сети ($\alpha = 0,5$);
- **Leiden** (Traag et al., 2019) — только сеть; разрешение подбирается бисекцией под заданное число сообществ (мелкие < 1% узлов присоединяются к соседнему крупному);
- **KEFRiN** (Shalileh & Mirkin, 2022) — k-means для сетей с признаками: минимизирует $\sum_k \sum_{i \in S_k} \|y_i - c_k\|^2 + \rho \|p_i - \lambda_k\|^2$, где p_i — строка сетевой матрицы после предобработки «модулярностью» $p_{ij} = p_i + p_j / p_{++}$. Это ровно k-means на $[Y, \sqrt{\rho} \cdot P]$ (вариант KEFRiNe статьи); 20 перезапусков, лучший по критерию.

Доля сети в спектральном методе $\alpha = 0,5$ — равные веса без настройки: метод служит ориентиром «сеть и признаки поровну», а не кандидатом с подобранными гиперпараметрами.

Доля сети в KEFRiN. Вместо фиксированного ρ задаём долю сети в общем разбросе ($\rho = s / (1-s) \cdot \|Y - \bar{Y}\|^2 / \|P - \bar{P}\|^2$) и проходим $s = 0 \dots 0,8$. Это наше дополнение к статье: при $N \gg$ числа признаков сетевой блок иначе подавляет признаки.

Развёртка при $k = 6$ (бутстреп — 20 подвыборок по 80%):

Доля сети	SW	CH	MQ	AVI	AVU	ANUI	Устойчивость ARI
0 (= k-means)	0,209	557	0,377	0,533	0,494	0,422	0,874
0,2	0,208	557	0,391	0,544	0,491	0,430	0,840
0,4	0,206	555	0,409	0,561	0,494	0,439	0,778
0,5	0,203	552	0,419	0,568	0,491	0,444	0,732
0,6	0,113	477	0,469	0,705	0,441	0,537	0,694
0,8	0,124	382	0,535	0,796	0,410	0,600	0,782

Правило выбора доли (в коде): наибольшая доля, при которой силуэт теряет не больше 0,005 относительно k-means. Это 0,4: модулярность растёт с 0,377 до 0,409 почти без потерь по признакам; после 0,5 силуэт падает вдвое — сеть начинает «перекрашивать» типы в географические сообщества синхронности.

Чувствительность к числу соседей k (results/knn_sensitivity.csv): при $k = 5, 10, 20, 30$ совпадение с итогом ARI = 0,87; 0,90; 0,87; 0,86, силуэт 0,20–0,21, сеть связана при всех k — типология от выбора k почти не зависит.

Веса блоков признаков (results/weights_sensitivity.csv). Итоговые веса (уровень 1, профиль 1, сезонность 0,7) выбраны так, чтобы три блока давали примерно равные доли общего разброса: 31%, 36% и 33%. При весе сезонности 1,0 её доля выросла бы до 50%, и разбиение определялось бы почти одной сезонностью. К весам типология чувствительнее, чем к настройкам сети, и это честно показываем. При изменении одного веса на $\pm 30\%$ макроуровень сохраняется (ARI 0,87–0,93), устойчивы «Столичные агломерации» (Жаккар $\geq 0,92$), «Арктика» ($\geq 0,82$) и «Города» ($\geq 0,73$); сдвигаются границы между «Глубинкой», «Аграрной периферией» и «Удалённой Сибирью» (ARI шести типов 0,53–0,84) — именно эти типы различаются в первую очередь сезонностью и структурой корзины, и их граница проходит по непрерывному спектру. Внешняя валидность во всех вариантах одинакова (0,37–0,39): выбор

весов не подгоняет результат под внешние метки. Поэтому выводы о сельских типах мы формулируем осторожнее, чем о севере и столицах.

6. Индексы качества (ICVI)

Индекс	Формула	Направление	Источник
SW	средний силуэт	↑	Rousseeuw (1987), sklearn
CH	межгрупповой / внутригрупповой разброс с поправкой на степени свободы	↑	Caliński & Harabasz (1974), sklearn
S_Dbw	Scat + Dens_bw; плотность в центре — точки своего кластера в радиусе stdev, в середине пары — точки обоих	↓	Halkidi & Vazirgiannis (2001)
AVI	$\text{mean}_k \frac{S_{kk}}{(S_{kk} + O_k)}, S_{kl}$ — вес рёбер между сообществами k и l, $O_k = \sum_{l \neq k} S_{kl}$	↑	Shalileh, Antonov, Tsyplakova (2025), ф. (18)–(22)
AVU	$(1/K) \sum_k \sum_{l \neq k} S_{kl} / (O_k + \text{In}_l - S_{kl})$	↓	там же
ANUI	$AVI / (1 + AVI \cdot AVU)$	↑	там же
MQ	модулярность Ньюмана–Гирвана $\sum_k [S_{kk}/2m - (d_k/2m)^2]$	↑	Newman & Girvan (2004)

SW, CH, S_Dbw считаются в пространстве признаков, AVI, AVU, ANUI и MQ — на основной сети corr (взвешенной). **MQ в Положении не расшифрован**; мы трактуем его как модулярность — стандартный индекс качества разбиения сети; альтернатива (MQ Манкоридиса) с точностью до множителя совпадает с AVI и ничего не добавила бы. Реализация проверена самотестом на аналитическом случае: две несвязные клики дают AVI = 1, AVU = 0, Q = 0,5; перенумерация меток индексы не меняет (python src/smc/metrics.py).

S_Dbw на наших данных требует оговорки: у части кластеров в радиусе stdev от центра нет точек своего кластера, Dens_bw от этого падает, и индекс «улучшается» с ростом k. Поэтому мы отдельно приводим Scat и Dens_bw, число вырожденных кластеров и сравниваем S_Dbw только при одинаковом k.

Выбор конфигурации — правило Коупленда. Метрики — «избиратели», конфигурации (метод × k) — «кандидаты»: А побеждает В, если лучше по большинству метрик; счёт — победы минус поражения. Голосуют SW, CH, S_Dbw, MQ, AVI, AVU и устойчивость; ANUI не голосует, так как выводится из AVI и AVU. Устойчивость — средний ARI между разбиением всей выборки и разбиениями 20 подвыборок по 80% MO.

Все методы при k = 6 (полная таблица всех 45 конфигураций — results/methods_icvi.csv):

Метод	SW ↑	CH ↑	S_Dbw ↓	MQ ↑	AVI ↑	AVU ↓	ANUI ↑	ARI устойч. ↑	Коупленд ↑	Внешняя валидность ↑
k-means (признаки)	0,209	557	0,761	0,377	0,533	0,494	0,422	0,874	16	0,366
Ward (признаки)	0,158	463	0,744	0,352	0,535	0,482	0,425	0,425	−28	0,394
Спектральный (признаки + сеть)	0,062	290	0,669	0,638	0,850	0,481	0,603	0,931	12	0,349
Leiden (сеть)	0,011	219	0,872	0,678	0,880	0,498	0,612	0,828	−16	0,308
KEFRiN (признаки + сеть)	0,206	555	0,753	0,409	0,561	0,494	0,439	0,778	20	0,374

«Внешняя валидность» — среднее V Крамера с пятью официальными метками и η² логарифма населения (раздел 9); она в выборе не участвует и служит независимой проверкой.

Картина типична для сетей с признаками: методы «только по признакам» выигрывают силуэт и CH, «только по сети» — модулярность и AVI, но первые не видят синхронности, а вторые дают силуэт около нуля (Leiden группирует соседей по региону, а не по экономике). KEFRiN при k ≤ 8 держит силуэт k-means и добавляет сетевую структуру. На лендинге все 45 конфигураций показаны на «карте компромиссов» (силуэт по признакам против модулярности сети, размер точки — устойчивость): методы только по признакам лежат справа внизу, только по сети — слева вверху, KEFRiN — на границе между ними.

В общем зачёте по 45 конфигурациям KEFRiN $k = 6$ набирает +20 (у KEFRiN $k = 4$ — максимальные +26). Если же устроить «турнир» только между пятью методами при $k = 6$, первым окажется спектральный: он лучший по AVU, S_Dbw и устойчивости и второй после Leiden по MQ и AVI, но его силуэт 0,06 — типы почти не различаются по профилю трат и не поддаются экономической интерпретации, ради которой строится типология. Поэтому метод выбирается на макроуровне, где KEFRiN — первый среди всех конфигураций, а детальный уровень строится тем же методом.

Структура слабая — и мы это учитываем. По шкале Kaufman & Rousseeuw (1990) силуэт 0,21 (не выше 0,25) означает, что обособленных кластеров в пространстве признаков нет: территории образуют непрерывный спектр, а не изолированные облака. Типы — устойчивое разбиение этого спектра, и доверие к ним опирается не на силуэт, а на устойчивость на подвыборках (ARI 0,78), превосходство над случайным разбиением по всем индексам, кроме AVU, и внешние официальные метки, которых модель не видела (раздел 9).

Итог против случайного разбиения (те же размеры типов, метки перемешаны, 50 повторов; $z > 0$ — лучше случайного с учётом направления индекса): SW 0,206 против -0,035 ($z = 14,5$); CH 555 против 1 ($z \approx 1\,980$); S_Dbw 0,753 против 1,859 ($z = 5,3$); MQ 0,409 против 0,000 ($z = 156$); AVI 0,561 против 0,166 ($z = 156$); ANUI 0,439 против 0,154 ($z = 131$); **AVU 0,494 против 0,468 ($z = -10$)**. AVU при $k = 6$ у всех методов (0,48–0,50) около случайного (0,47) и даже хуже: на kNN-графе синхронности связи между типами сосредоточены между соседними по профилю типами, что AVU штрафует. Поэтому на этой сети AVU не различает разбиения; выводы о сетевом качестве опираются на AVI, MQ и ANUI. S_Dbw: Scat = 0,550, Dens_bw = 0,204, у 3 из 6 кластеров нулевая плотность в центре — сравниваем только при одном k .

Правило выбора. Метод и макроуровень — глобальный максимум Коупленда: KEFRiN $k = 4$ (+26; следующие — k-means $k = 8$ (+24) с устойчивостью 0,70 и спектральный $k = 8$ и KEFRiN $k = 9$ (по +22) с 0,67 и 0,58). Детальный уровень — тот же метод при наименьшем $k \geq 6$ (при 4 типах «Удалённая Сибирь» растворяется между «Городами», «Севером» и «Сельской Россией», а два сельских уклада сливаются) с устойчивостью $ARI \geq 0,75$: KEFRiN $k = 6$. Устойчивость KEFRiN по k : 0,975 (4), 0,892 (5), 0,778 (6), 0,607 (7), 0,613 (8), 0,577 (9) — начиная с 7 типов границы на подвыборках не воспроизводятся.

Чувствительность правила (results/selection_sensitivity.csv):

Порог устойчивости	0,65	0,70	0,75	0,80
Наше правило: тот же метод, наименьшее $k \geq 6$	KEFRiN 6	KEFRiN 6	KEFRiN 6	— (нет $k \geq 6$)
Альтернатива: лучший по Коупленду любой метод с $k \geq 6$	k-means 8	k-means 8	KEFRiN 6	k-means 6

Правило «любой метод» неустойчиво к порогу и даёт уровни, которые не вкладываются друг в друга; наше правило даёт один ответ на всём диапазоне 0,65–0,75 и сохраняет иерархию (вложенность 92,7%).

S_Dbw смещён в пользу больших k (раздел 6), поэтому проверено, не он ли решил выбор: без S_Dbw среди «голосующих» первым остаётся KEFRiN $k = 4$ (+32 вместо +26).

Когда какой метод уместен

Метод	Что использует	Сильная сторона	Ограничение на наших данных	Когда уместен
k-means	Только признаки	Быстро, устойчиво, лучший силуэт	Не видит сети: синхронные, но разные по профилю МО не связываются	Сеть не нужна или ненадёжна
Ward	Только признаки	Иерархия типов «из коробки»	Неустойчив на подвыборках ($ARI \approx 0,4$)	Разведка иерархии, не итог
Спектральный	Смесь сходств признаков и сети	Высокие графовые индексы, устойчив	Силуэт $\approx 0,06$: типы не различаются по профилю трат	Важнее связность, чем интерпретация
Leiden	Только сеть	Максимальная модулярность	Силуэт ≈ 0 : группирует соседей по региону, а не по экономике	Поиск сообществ синхронности
KEFRiN	Признаки и сеть в одном критерии	При $k \leq 8$ держит силуэт k-means и добавляет сетевую структуру	Нужна настройка доли сети; без неё при $N \gg$ признаков сеть доминирует	Атрибутированные сети — наш итог

7. Динамика

Окна. 13 скользящих 12-месячных окон с шагом месяц: янв–дек 2023, фев 2023 – янв 2024, ..., янв–дек 2024. В каждом окне ровно по одному каждому календарному месяцу, поэтому сезонность не создаёт ложных переходов. Признаки окна считаются по тем же формулам и масштабируются той же фиксированной шкалой.

Сеть каждого окна строится заново (корреляции по 12 месяцам), разбиение окна — KEFRiN в пространстве $[x_t, \sqrt{p \cdot p_t}]$ с тёплым стартом из центров **основной** типологии (а не предыдущего окна). Старт от предыдущего окна мы проверили и отвергли (python scripts/anchor_check.py): ошибки окон накапливаются — после весеннего провала цепочка уже не восстанавливается, и в последнем окне сходство типов с основными (средний Жаккар) 0,59 против 0,72 при якорном старте. Номера типов сопоставляются с основными по максимальному пересечению (венгерский алгоритм).

Значимый переход. Для МО считаем уверенность принадлежности $m_i = (d2 - d1)/d2$, где $d1, d2$ — расстояния до ближайшего и второго центра. Переход 2023 → 2024 значим, если тип различается и уверенность не ниже τ в **обоих** непересекающихся окнах (янв–дек 2023 и янв–дек 2024). Остальные смены типа — колебания на границе соседних типов.

Качество по окнам. Силуэт окон 0,19–0,22, модулярность 0,34–0,41; ARI соседних окон 0,57–0,87; среднее сходство типов окна с основными (Жаккар) 0,52–0,76. Честно о слабом месте: за год формально меняют тип 33% МО, а в окнах весны 2024 года отдельные типы окна совпадают с основными лишь на 14–25% (минимальный Жаккар). Годовое окно — шумная оценка профиля, поэтому выводы о динамике строятся только на значимых переходах, а не на формальных сменах типа.

Чувствительность к порогу уверенности τ :

τ	0	0,05	0,10	0,15	0,20	0,25	0,30
Значимых переходов	656	390	215	116	53	23	9

Правило «тип одинаков в трёх первых и трёх последних окнах» дало бы 205 переходов, но соседние окна пересекаются на 10 месяцев из 12, поэтому это слабое доказательство; мы его не используем.

Значимые переходы 2023 → 2024 ($\tau = 0,15$): «Аграрная периферия с летним пиком» → «Глубинка европейской части и Урала» — 84; обратно — 23; «Удалённая Сибирь и горы» → «Города и промышленные центры» — 4; единичные прочие. Главный поток однонаправленный: у части МО «Аграрной периферии» исчез летний подъём трат, и они перестали отличаться от «Глубинки». Сдвиг виден прежде всего в общепите: медиана летнего избытка трат в общепите к стране у 84 перешедших МО — +1% в 2023 и –5% в 2024, у 277 оставшихся в «Аграрной периферии» — +5% и +10%; по общим тратам изменение меньше (0% → –0,7%). Сильнее всего у перешедших сдвинулись летний избыток общепита и общий летний избыток — признаки, по которым эти два типа различаются (вместе с долей транспорта). При симметричном шуме на границе встречные потоки были бы равны; 84 против 23 — биномиальный тест $p \approx 2 \cdot 10^{-9}$ (results/dynamics_asymmetry.json). Переходы рассеяны по многим регионам (больше всего — Ивановская область, 6 МО; Костромская, Новосибирская, Самарская — по 5), то есть это не шок одного региона, а широкий сдвиг сезонного уклада. Это кандидат на проверку, а не установленная причина: гипотезы — меньше летних приезжих (туристы, дачники) и закрытие сезонных кафе, изменение сезонной занятости, отъезд жителей летом.

8. Типы локальных экономик

Медианы по типу за 2023–2024 гг.; доли — от трат «Все категории»; «Миркин» — три признака с наибольшим относительным отклонением среднего типа от среднего по всем МО $((c_{kv} - g_v)/g_v, Alvandyan \& Shalileh, 2024)$; медоиды — МО, ближайšie к центру типа.

Макротип → тип	МО	Траты, Р/мес. на жителя	Продукты	Общепит	Транспорт	Маркетплейсы	Население (медиана)	Миркин	Типичные МО
Столичные агломерации → Столичные агломерации и центры с высокими тратами	318	46 316	33,1%	7,5%	7,3%	12,0%	82 380	общепит +120%, траты +64%, доступность рынков +46%	районы Москвы (Чертаново, Центральное, Орехово-Борисово Южное, Головинский)
Города → Города и промышленные центры	495	30 096	42,0%	4,0%	5,9%	13,3%	50 549	общепит +22%, сезонность –8%, траты +7%	Бузулук, Беловский, Канск, Краснокамский
Сельская Россия → Глубинка европейской части и Урала	484	22 106	47,4%	1,9%	4,7%	15,9%	18 827	общепит –38%, траты –22%, транспорт –21%	Верхнеуральский, Печорский, Касимовский, Сергиевский
Сельская Россия → Аграрная периферия с летним пиком	560	20 744	48,1%	1,4%	5,7%	14,9%	14 280	общепит –54%, траты –27%, прочее –13%	Знаменский (Омская обл.), Абанский, Суксунский
Переходный → Удалённая Сибирь и горы	113	24 976	44,8%	2,6%	7,2%	12,4%	15 634	сезонность +57%, доступность рынков –38%, транспорт +29%	Аларский, Усть-Коксинский, Ольхонский
Север → Арктика и Крайний Север	46	43 768	41,4%	4,3%	4,2%	8,7%	12 082	сезонность +118%, траты +61%, доступность рынков –49%	Оймяконский, Заполярный (НАО), Приуральский (ЯНАО)

Как читать типы. Главная ось — «город — село»: уровень трат на жителя растёт вместе с долей общепита и падает вместе с долей продуктов (корреляция признаков 0,81 и –0,71). Вторая ось — удалённость: на севере и в Сибири растёт сезонность, доступность рынков на севере вдвое ниже, в удалённой Сибири — на 40%; на севере доля маркетплейсов минимальна (8,7% против 13,9% по России), в удалённой Сибири лишь немного ниже (12,4%), зато доля транспорта 7,2% при 5,7% по России — на уровне «Столичных» (7,3%). Третья ось — сезонный уклад: у «Аграрной периферии» летом траты, прежде всего в общепите, растут сильнее, чем по стране (летний избыток общепита +3%), у «Глубинки» — слабее (–2,5%); по общим тратам разница меньше (+0,4% против –1,4%).

Состав первого типа. 87% «Столичных агломераций» — районы Москвы и Петербурга и города их областей; остальное — крупные центры Сибири, Урала, Дальнего Востока и Севера (Новосибирск, Екатеринбург, Красноярск, Владивосток, Хабаровск, Якутск, Мурманск). 44 из 64 МО со статусом «административный центр субъекта» в справочнике, включая Казань, Нижний Новгород, Самару и Уфу, — в «Городах». Это не ошибка размера: тип описывает уровень и структуру трат на жителя, а все города-миллионники лежат на границе двух типов (уверенность < 0,15), что и показывает лендинг.

Маркетплейсы — гипотеза, а не вывод. Самая высокая доля маркетплейсов в безналичных тратах — в европейской глубинке. Возможное объяснение — онлайн-торговля замещает редкую розницу; но часть эффекта

механическая: в сёлах офлайн-покупки чаще оплачивают наличными, и доля онлайн среди *безналичных* трат там выше. Разделить эти объяснения без данных о наличных нельзя.

9. Внешняя проверка

Модель не видела ни одной из перечисленных характеристик.

Внешняя характеристика	Связь с 6 типами
Вид МО (городской округ / муниципальный район / округ / район города)	V Крамера 0,54
Регион	V Крамера 0,65
Индекс доступности рынков СберИндекса	$\eta^2 = 0,40$
Численность населения 2024 (Росстат, логарифм)	$\eta^2 = 0,43$
Арктическая зона (Указ № 296)	V = 0,59
Крайний Север и приравненные местности	V = 0,52
Моногорода (кат. 1–3, № 1398-р)	V = 0,27
Ядра агломераций (перечень опорных населённых пунктов)	V = 0,22
Столицы регионов	V = 0,22

Доли официальных категорий по типам: «Арктика и Крайний Север» — 100% Крайний Север, 67% Арктическая зона; «Удалённая Сибирь и горы» — 40% Крайний Север; «Города и промышленные центры» — 24% моногорода (максимум), 8% ядра агломераций, 9% столицы регионов; сельские типы — 0% ядер агломераций и столиц. Источники меток и ограничения сопоставления — [data/external/README.md](#).

Типы против административного деления. Простейшая альтернатива типологии — официальный вид МО (городской округ, муниципальный район, муниципальный округ, район города). На тех же внешних метках:

Внешний показатель	6 типов	Вид МО (4 категории)
η^2 логарифма численности населения	0,43	0,30
η^2 доступности рынков	0,40	0,39
V Крамера: Арктическая зона	0,59	0,09
V Крамера: Крайний Север	0,52	0,14
V Крамера: моногорода	0,27	0,21
V Крамера: ядра агломераций	0,22	0,27
V Крамера: столицы регионов	0,22	0,33

Типы сильнее вида МО по пяти показателям из семи. Вид МО выигрывает там, где метка почти совпадает с ним по определению (столица региона почти всегда — городской округ). Типология добавляет к административному делению то, чего в нём нет: север, удалённость и уклад потребления.

10. Проверка метода на стране с известной типологией

Как типологизируют локальные экономики в мире. США (USDA ERS, County Typology Codes 2025) относят округ к фермерскому, добывающему, обрабатывающему, государственному или рекреационному типу, если доля отрасли в заработках или занятости выше порога «среднее по неметро-округам + 1 СКО» (рекреация — композитный балл с сезонным жильём). Канада (Statistics Canada, Index of Remoteness; Alasia et al., 2017) измеряет удалённость гравитационной формулой $A_i = \sum p_{0P_j} / C_{ij}$ (население центров в пределах $\approx 2,5$ ч пути, делённое на издержки доступа) — той же формы, что индекс доступности рынков СберИндекса $MA_o = \sum n_d / \tau_{od}$ (формула — в описании набора в конкурсном архиве); у StatCan шкала перевернута: больше — удалённее. ЕС и ОЭСР (DEGURBA, TL3), Австралия (ARIA+), Бразилия (REGIC) — пороги урбанизации, удалённости и иерархии центров. Закономерность: официальные типологии строятся **пороговыми правилами по структуре производства и удалённости**; открытых

местных данных о тратах вместе с типологией нет ни в одной из рассмотренных стран. Подробный обзор и 37 источников с отметкой о проверке — [docs/international_review.md](#).

Выбор аналога. По пространственной неоднородности (огромная территория, редконаселённый север, ресурсные и моногорода, агломерации, федеративность) ближе всего к России Канада и США; размеченная типология экономик по местным единицам и открытые помесячные карточные данные есть только у США — их и берём для проверки.

Проверка на США (`scripts/us_check.py`). Opportunity Insights EconomicTracker (Affinity, 1 971 округ, 2020-01...2026-07) даёт по округам только общий индекс трат к январю 2020 — без категорий и уровней. Из него строим 9 признаков динамики и сезонности (шок 2020, восстановление, пик 2021, уровень 2023–2024, рост, волатильность, сезонная амплитуда, лето против зимы, декабрьский пик). k-means (k = 6) против официального кода `Industry_Dependence_2025`: **ARI = 0,029, NMI = 0,020**. Даже обучаемый случайный лес достигает сбалансированной точности 0,26 при случайной 0,17; AUC «тип против остальных»: фермерские 0,75, рекреационные 0,66, добывающие 0,62, обрабатывающие 0,62, государственные 0,58.

Вывод для России. Траты жителей несут сигнал о типе экономики, но не повторяют производственную классификацию: это другая ось — уклад потребления. Поэтому (1) типы названы по профилю потребления, а не по отрасли; (2) их проверка опирается на российские официальные категории, которые описывают условия жизни (Север, Арктика, моногорода, агломерации, численность), — и они с типами согласуются (раздел 9); (3) для канадской формулы удалённости у нас уже есть прямой аналог — индекс доступности рынков, который типы объясняют на 40%, не видя его.

11. Как использовать результат

- **Сравнение «похожего с похожим».** Бенчмарки, рейтинги и оценку программ развития корректнее строить внутри типа: сельский район Омской области сравнивать с аграрной периферией, а не с областным центром. Лендинг для любого МО показывает тип, отклонение от медианы типа и ближайших соседей по синхронности трат.
- **Ранний сигнал.** Значимый переход — уверенная смена уклада потребления, а не колебание на границе. Такие МО — кандидаты для проверки причин (занятость, доходы, сезонная миграция). Пересчёт на новых месяцах — одной командой.
- **Настройка мер поддержки.** Типы отражают условия жизни: на севере доля маркетплейсов минимальна (доставка сложна), в удалённой Сибири высока доля транспорта, а в европейской глубинке доля маркетплейсов в безналичных тратах максимальна (замещение редкой розницы — гипотеза, см. раздел 8) — подсказки для логистики, розницы и цифровых сервисов.
- **Расширение.** Новый признак узла (зарплаты, занятость Росстата) — функция в `features.py`, новое правило рёбер (мобильность, потоки) — функция в `graphs.py`; состав правил, методов и гиперпараметры задаются в YAML.

Три разобранных примера (на лендинге — раздел «Как использовать», кнопка открывает МО на карте).

Пример	Факты	Вывод
Богградский район (Хакасия), «Аграрная периферия»	20 278 Р на жителя в месяц: на 22% ниже медианы МО своего региона и на 2% ниже медианы своего типа	Против региона район выглядит отстающим, против похожих — обычным. Рейтинг внутри типа не путает сельский уклад с отставанием
Холмский район (Новгородская обл.), переход «Аграрная периферия» → «Глубинка»	летний избыток трат в общепите к стране +8,9% в 2023 и –21,6% в 2024; уверенность в типе 0,30 / 0,29	Летний подъём сменился провалом — кандидат для проверки сезонного туризма, дачников и отъезда жителей, а не установленная причина
Оймьяконский район (Якутия), «Арктика и Крайний Север»	траты на жителя на 95% выше медианы России; доля маркетплейсов 6,1% против 13,9%; доступность рынков 127 из 1000	Высокие траты при малой доле онлайн-покупок: тип собирает территории с похожими условиями доставки и цен — список для логистики и розницы

12. Ограничения

- Траты — безналичные и номинальные; доля наличных различается между территориями и может смещать уровень. Центрирование медианой страны убирает общий рост, но не региональные различия в доле безналичных платежей.
- Типология описывает структуру потребления, а не производства; названия типов — интерпретация профилей, подтверждённая внешними признаками, а не официальная классификация.
- Двух лет мало для выводов о долгосрочных траекториях; значимые переходы 2023 → 2024 — кандидаты для проверки, а не установленные сдвиги.
- Отсутствие восьми регионов в наборе организатора делает типологию неполной для юга европейской части; ДНР, ЛНР, Запорожской и Херсонской областей нет ни в справочнике МО, ни в данных.
- Граница между «Глубинкой», «Аграрной периферией» и «Удалённой Сибирью» чувствительна к весам блоков признаков (раздел 5); макроуровень, «Столичные агломерации», «Города» и «Арктика» устойчивы.

13. Воспроизведение

```
pip install -r requirements.txt
python scripts/download_data.py
python run.py --config configs/default.yaml # ~13 мин; --fast без бутстрапа ~3 мин
```

Все гиперпараметры в `configs/default.yaml`, случайность фиксирована (`seed: 42`). Таблицы всех сравнений — в `results/`; лендинг читает `site/data/`. Ключевые числа и сравнения этого отчёта, README и лендинга пересчитываются по результатам скриптом `python scripts/check_claims.py` (43 утверждения). Код: <https://github.com/lebedev-git/sberindex-mo-clusters>; лендинг: <https://lebedev-git.github.io/sberindex-mo-clusters/>

Литература

- Shalileh S., Antonov A., Tsyplakova D. (2025). Doklady Mathematics 112(3): 553–564. <https://doi.org/10.1134/S1064562425700589>
- Shalileh S., Mirkin B. (2022). Community partitioning over feature-rich networks using an extended k-means method. Entropy 24(5): 626. <https://doi.org/10.3390/e24050626>
- Alvandyan, Shalileh (2024). Doklady Mathematics. <https://link.springer.com/article/10.1134/S1064562424602002> (правило интерпретации Миркина)
- Halkidi M., Vazirgiannis M. (2001). Clustering validity assessment: finding the optimal partitioning of a data set. ICDM.
- Biswas A., Biswas B. (2017). Defining quality metrics for graph clustering evaluation. Expert Systems with Applications 71.
- Newman M., Girvan M. (2004). Finding and evaluating community structure in networks. Phys. Rev. E 69.
- Traag V., Waltman L., van Eck N. (2019). From Louvain to Leiden. Scientific Reports 9.
- Chakrabarti D., Kumar R., Tomkins A. (2006). Evolutionary clustering. KDD.
- Aitchison J. (1986). The Statistical Analysis of Compositional Data (CLR-преобразование).
- Kaufman L., Rousseeuw P. J. (1990). Finding Groups in Data: An Introduction to Cluster Analysis. Wiley (шкала силуэта).
- Alasia A., Bédard F., Bélanger J., Guimond E., Penney C. (2017). Measuring remoteness and accessibility: A set of indices for Canadian communities. Statistics Canada, 18-001-X. <https://www150.statcan.gc.ca/n1/pub/18-001-x/18-001-x2017002-eng.htm>
- СберИндекс. Описание набора данных хакатона по муниципальным данным. <https://sberindex.ru/ru/research/data-sense-opisanie-nabora-dannikh-khakatona-sberindeksa-po-munitsipalnim-dannim>